

FACULTÉS DES SCIENCES (FDS)

**Formation de Renforcement du Secteur Technologique (FRST)
Sciences des Données, IA & Mathématiques pour l'IA**

— PROJET INTÉGRATEUR (CAPSTONE) —

Segmentation des ménages haïtiens exclus du crédit formel : *Identification des profils prioritaires pour le ciblage d'une offre de microcrédit.*

Équipe de réalisation du projet :

Davidson RIGAUD- Coordonnateur
Abdarare HERARD- Membre
Roodson FRANCOIS - Membre

**Promotion
2025-2026**

Date de soumission

Juillet 2026 - Haïti

Remerciements

Les auteurs de ce travail tiennent à exprimer leur profonde gratitude envers toutes les personnes et institutions qui ont rendu ce projet possible.

Nous rendons grâce à **Dieu Tout-Puissant** pour la sagesse, la force et la persévérance qu'Il nous a accordées tout au long de ce programme. C'est par Sa grâce que nous avons pu mener ce travail à son terme.

Nous adressons nos sincères remerciements à la **Banque de la République d'Haïti (BRH)** pour avoir financé et rendu possible cette formation en Sciences des Données et Intelligence Artificielle. Cette initiative témoigne de l'engagement de l'institution envers le renforcement des capacités analytiques au service de l'inclusion financière en Haïti.

Nous exprimons notre profonde reconnaissance à l'ensemble du **corps professoral de la Faculté des Sciences (FDS)** pour la qualité de l'enseignement dispensé, la rigueur méthodologique transmise et le soutien constant apporté tout au long du programme. Chaque cours a constitué un apport précieux à la réalisation de ce projet.

Nous remercions chaleureusement le **staff de coordination du programme FRST-FDS** pour leur disponibilité, leur organisation et leur accompagnement administratif et logistique tout au long de la formation.

Nos remerciements les plus sincères vont à notre encadrant académique, **Monsieur Evens TOUSSAINT**, pour ses orientations rigoureuses, ses retours constructifs et la qualité de son suivi tout au long des huit étapes de ce projet. Sa disponibilité et son exigence ont été déterminantes dans la qualité du travail produit.

Enfin, nous remercions nos familles et proches pour leur soutien indéfectible, leur patience et leurs encouragements constants tout au long de cette formation.

Résumé exécutif

En Haïti, 46 % de la population adulte est totalement exclue du système financier formel et seulement 4 % ont accès au crédit formel (FinScope 2018). Face à ce déficit structurel, les institutions de microfinance (IMF) peinent à identifier les ménages présentant le potentiel d'adoption le plus favorable, faute d'une cartographie fine des profils socio-économiques de la population non bancarisée.

Ce projet applique des méthodes de segmentation non supervisée à 4 016 ménages haïtiens exclus du crédit formel, issus d'un dataset synthétique calibré sur les statistiques officielles FinScope Consumer Haïti 2018. Après une analyse exploratoire approfondie, une réduction de dimension par AFDM (12 composantes, 85 % de variance expliquée) et la comparaison de cinq algorithmes de clustering, le modèle K-means $k=6$ est retenu comme modèle final (silhouette=0,268, Calinski-Harabasz=638,12, Davies-Bouldin=1,463, ARI Bootstrap=1,000 sur 50 runs).

Six segments distincts sont identifiés. Les salariés formels (7,6 %, score de priorité 80,3/100) et les commerçants informels (25,5 %, score 51,3/100) constituent les cibles prioritaires pour une offre de microcrédit. À l'opposé, les agriculteurs vulnérables (27,8 %, score 12,6/100) requièrent des programmes d'accompagnement avant tout accès au crédit. Un pipeline de prédiction reproductible est sauvegardé et validé à 100 %, prêt à être appliqué aux microdonnées officielles de la BRH.

Mots-clés : *segmentation non supervisée, K-means, AFDM, inclusion financière, microcrédit, Haïti, FinScope 2018, profils socio-économiques, clustering, pipeline de prédiction.*

Table des matieres

Liste des abréviations.....	5
1- Problématique et contexte	6
1.1 Contexte de l'inclusion financière en Haïti	6
1.2 Problème métier	6
1.3 Question analytique principale et objectifs.....	7
1.4 Acteurs et utilisateurs des résultats	7
2- Jeu de données	8
2.1 Source et nature des données	8
2.2 Variables retenues pour la modélisation	8
3 - Préparation et exploration des données	10
3.1 Opérations de préparation	10
3.2 Statistiques descriptives	11
3.3 Analyse bivariée - Constats structurants.....	12
3.4 Tests statistiques	14
3.5 Vérification des hypothèses analytiques	15
4 - Méthodologie et choix du modèle	16
4.1 Type de problème et justification de l'approche	16
4.2 Réduction de dimension - AFDM.....	16
4.3 Choix du nombre de clusters k.....	17
4.4 Algorithmes appliqués et comparaison	19
5 - Fondements mathématiques mobilisés	20
5.1 Standardisation (Z-score).....	20
5.2 Analyse Factorielle de Données Mixtes (AFDM)	20
5.3 Algorithme K-means.....	20
5.4 Classification Ascendante Hiérarchique (CAH) - Critère de Ward.....	21
5.5 Métriques d'évaluation du clustering	21
6- Analyse OLAP et tableau de bord Power BI.....	22
Modèle OLAP- Faits, mesures et dimensions.....	22
Tableau de bord - 4 pages thématiques.....	22
Score de ciblage microcrédit par département (filtre Rural)	22
7 - Résultats et évaluation	24
7.1 Performance du modèle final	24

7.2 Analyse de silhouette par segment.....	25
7.3 Pouvoir discriminant des variables	25
7.4 Les six segments identifiés	27
7.5 Répartition géographique des segments.....	30
8- Interprétation, limites et discussion critique.....	31
8.1 Ce qu'apprennent les résultats	31
8.2 Utilité pratique du modèle	31
8.3 Limites identifiées.....	32
8.4 Discussion critique.....	33
9- Considérations éthiques et pratiques	35
9.1 Confidentialité et protection des données	35
9.2 Biais potentiels et risques de discrimination.....	35
9.3 Conditions d'usage responsable	36
Recommandations.....	37
Pour les IMF et banques commerciales	37
Pour la Banque de la République d'Haïti (BRH)	37
Conclusion	39
Références bibliographiques.....	40
Annexes.....	41

Liste des abréviations

Abréviation	Signification
AFDM	Analyse Factorielle de Données Mixtes
ACP	Analyse en Composantes Principales
ACM	Analyse des Correspondances Multiples
ARI	Adjusted Rand Index (Indice de Rand Ajusté)
BRH	Banque de la République d'Haïti
CAH	Classification Ascendante Hiérarchique
CH	Calinski-Harabasz (indice d'évaluation du clustering)
CIN	Carte d'Identification Nationale
DB	Davies-Bouldin (indice d'évaluation du clustering)
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
EDA	Exploratory Data Analysis (Analyse Exploratoire des Données)
FDS	Faculté des Sciences
FINDEX	Global Financial Inclusion Database (Banque Mondiale)
FRST	Formation et Renforcement du Secteur Technologique
HTG	Gourde haïtienne (monnaie nationale d'Haïti)
IMF	Institution de Microfinance
KPI	Key Performance Indicator (Indicateur Clé de Performance)
MCN	Micro Crédit National (IMF haïtienne)
NIF	Numéro d'Identification Fiscale
OLAP	Online Analytical Processing
PAM	Partitioning Around Medoids (K-médoides)
PC	Principal Component (Composante Principale)
PCA	Principal Component Analysis
UEH	Université d'État d'Haïti

1- Problématique et contexte

1.1 Contexte de l'inclusion financière en Haïti

Haïti présente l'un des taux d'exclusion financière les plus élevés de la région caribéenne. Selon l'enquête FinScope Consumer Haïti 2018, référence nationale publiée par la BRH, DAI Finance Inclusive et FinMark Trust en avril 2019, 46 % de la population adulte est totalement exclue de tout service financier, 10 % n'utilisent que des mécanismes informels, et seulement 11 % disposent d'un compte bancaire. La pénétration du crédit formel reste marginale : 4 % des adultes haïtiens y ont accès.

Cette exclusion n'est pas uniforme. Elle est structurée par le secteur d'activité, le milieu de résidence (urbain/rural), le niveau d'éducation et les comportements financiers. Le milieu rural concentre les profils les plus exposés : revenu médian 1 540 HTG contre 3 380 HTG en milieu urbain (Mann-Whitney $U=2\,200\,678$, $p<10^{-57}$). Le Nord-Ouest affiche le taux de manque d'argent fréquent le plus élevé (75 %), signalant une vulnérabilité structurelle persistante.

Indicateur	Valeur (FinScope 2018)	Implication pour le microcrédit
Taux de bancarisation	11 %	Bassin de clientèle très limité pour les banques commerciales
Exclusion financière totale	46 %	Population cible principale pour les IMF
Accès au crédit formel	4 %	Demande non couverte massive
Possession CIN	65,3 % (pop. cible)	34,7 % sans document, frein direct au crédit
Participation aux tontines	40,6 % (pop. cible)	Proxy de discipline financière exploitable
Gap mobile money	49 points de %	Potentiel numérique inexploité (61 % téléphone vs 12 % mobile money)

Tableau 1 : Indicateurs clés d'inclusion financière en Haïti (FinScope 2018)

1.2 Problème métier

Les IMF haïtiennes telles que Fonkoze, SOGESOL, ACME et les banques commerciales souhaitant développer une offre de microcrédit se heurtent à une contrainte fondamentale : l'absence de segmentation fine de la population non bancarisée. Sans historique de crédit, sans données transactionnelles et sans cartographie des profils, elles appliquent des critères d'éligibilité

uniformes qui excluent mécaniquement des segments pourtant solvables ou à fort potentiel d'adoption. Ce déficit de connaissance entraîne une mauvaise allocation des ressources commerciales.

Problème central : comment identifier, parmi les 4 016 ménages haïtiens exclus du crédit formel, les groupes présentant les profils socio-économiques et comportementaux les plus favorables à l'adoption et au remboursement d'un microcrédit, en l'absence de tout historique de crédit ?

1.3 Question analytique principale et objectifs

Peut-on regrouper les ménages haïtiens exclus du crédit formel en segments distincts selon leur profil socio-économique et leurs comportements financiers, afin d'identifier ceux qui sont les plus susceptibles d'adopter et de rembourser un microcrédit ?

Objectif	Description
Général	Produire une segmentation opérationnelle des ménages exclus du crédit formel, utilisable par une IMF ou banque commerciale pour prioriser le ciblage d'une offre de microcrédit en Haïti.
Spécifique 1	Explorer et décrire statistiquement les caractéristiques socio-économiques et financières de la population cible.
Spécifique 2	Construire et comparer cinq algorithmes de clustering sur données mixtes encodées via AFDM.
Spécifique 3	Identifier et nommer les segments résultants avec leurs profils statistiques et leur potentiel de bancabilisation.
Spécifique 4	Sauvegarder un pipeline de prédiction reproductible applicable aux microdonnées officielles BRH.

Tableau 2 : Objectifs du projet

1.4 Acteurs et utilisateurs des résultats

Acteur	Usage attendu
IMF (Fonkoze, SOGESOL, ACME)	Priorisation commerciale par segment — adaptation du produit microcrédit au profil
Banques commerciales haïtiennes	Identification des segments pré-bancabilisables — développement de produits adaptés
Banque de la République d'Haïti (BRH)	Orientation de la stratégie nationale d'inclusion financière — cartographie des zones prioritaires
Fintechs et opérateurs mobile money	Ciblage des zones à fort gap d'adoption numérique — développement du mobile lending

Tableau 3 : Acteurs et utilisation des résultats

2- Jeu de données

2.1 Source et nature des données

La source de référence est l'enquête FinScope Consumer Haïti 2018, conduite par la BRH, DAI Finance Inclusive et FinMark Trust entre mai et octobre 2018, auprès de 4 269 adultes haïtiens (15 ans et plus) dans les dix départements du pays. Les microdonnées officielles n'étant pas disponibles en accès académique au moment de l'étude, une demande ayant été transmise à la BRH via le programme FRST-FDS sans réponse à la date de rédaction, un dataset synthétique a été construit par simulation calibrée sur les statistiques officielles publiées dans le rapport FinScope 2018.

La simulation utilise une graine aléatoire fixée (`random_state=2018`) pour garantir la reproductibilité. Les distributions marginales sont calées sur les valeurs officielles et des biais de collecte réalistes sont intégrés (sous-représentation rurale, 15 % de revenus manquants ou refusés). Une feuille de vérification statistique compare systématiquement les proportions du dataset aux valeurs officielles.

Paramètre	Valeur
Taille totale	4 269 individus × 34 variables
Population cible (filtre)	4 016 individus — Jamais_Eu_Credit_Formel = 'Oui' (94,1 %)
Variables numériques analytiques	2 (Age, Revenu_Mensuel_HTG)
Variables binaires (Oui/Non)	16 dont 6 retenues pour le clustering
Variables catégorielles ordinales	3 (Niveau_Education, Planification_Financiere, Niveau_Inclusion_Financiere)
Variable nominale	1 (Secteur_Activite — 6 modalités)
Valeurs manquantes sur variables clustering	0 (après imputation par médiane par groupe)
Doublons	0

Tableau 4 : Caractéristiques du dataset

2.2 Variables retenues pour la modélisation

Sur les 34 variables disponibles, 12 sont retenues pour la segmentation. Le choix repose sur leur pertinence métier pour le ciblage microcrédit et leur pouvoir discriminant confirmé par les tests

statistiques de l'EDA. Deux variables sont exclues du clustering : Montant_Credit_Formel_HTG (valeur nulle sur toute la population cible) et Poids_Sondage (coefficient technique sans valeur analytique). L'âge et le crédit informel, bien que retenus initialement, s'avèrent non discriminants , avec ($Eta^2 \approx 0$) , ils seront recommandés pour suppression dans la version 2 du modèle.

Variable	Type	Justification métier
Revenu_Mensuel_HTG	Numérique	Variable la plus discriminante ($Eta^2=0,542$), proxy de capacité de remboursement
Age	Numérique	Non discriminant ($Eta^2 \approx 0$), conservé pour la description
CIN_Carte_Identite	Binaire	Éligibilité documentaire, exigée par les IMF pour ouvrir un dossier de crédit
Membre_Tontine_Sol	Binaire	Proxy de discipline d'épargne, signal fort de bancabilité informelle
Mobile_Money	Binaire	Adoption des services financiers numériques, potentiel mobile lending
Credit_Informel	Binaire	Signal d'un besoin non couvert, non discriminant ($Eta^2 \approx 0$)
Manque_Argent_Frequent	Binaire	Indicateur de vulnérabilité financière courante
Epargne_Formelle	Binaire	Proximité avec le système financier formel
Niveau_Education	Ordinale (0-3)	Capital humain, corrélé au revenu et à la capacité de remboursement
Planification_Financiere	Ordinale (0-3)	Maturité financière, proxy de gestion disciplinée
Niveau_Inclusion_Financiere	Ordinale (0-3)	Mesure directe de l'intégration dans le système financier ($Eta^2=0,085$)
Secteur_Activite	Nominale ,6 one-hot	Variable structurante, V Cramér=1,000 avec les clusters

Tableau 5 : Variables retenues pour la modélisation (12 variables → 17 colonnes après encodage)

3 - Préparation et exploration des données

3.1 Opérations de préparation

La préparation des données suit un protocole rigoureux en six étapes, visant à produire une matrice X_{scaled} de $4\,016 \times 17$ colonnes standardisées, adaptée à l'AFDM et au clustering. Le dataset ne présente aucune valeur manquante sur les 12 variables de clustering après imputation, ni aucun doublon.

Étape	Opération	Variables concernées	Justification
1	Filtrage population cible	Jamais_Eu_Credit_Formel = 'Oui'	Extraction des 4 016 individus (94,1 %), population d'analyse
2	Imputation revenus manquants	Revenu_Mensuel_HTG (15 % manquants)	Médiane par groupe (Secteur $\times$ Milieu), préserve l'hétérogénéité
3	Transformation logarithmique	Revenu_Mensuel_HTG en Revenu_log	Skewness = 2,12 qui réduit à -2,73 après log1p, atténue les extrêmes
4	Encodage binaire	6 variables Oui/Non	0/1, requis pour AFDM et K-means
5	Encodage ordinal	Niveau_Education, Planification_Financiere, Niveau_Inclusion_Financiere	Échelle 0-3 respectant l'ordre logique des modalités
6	One-hot encoding	Secteur_Activite en 6 colonnes	Variable nominale sans ordre naturel, 6 secteurs distincts
7	Standardisation Z-score	Toutes les 17 colonnes finales	$(x-\mu)/\sigma$ via StandardScaler, mise à l'échelle homogène

Tableau 6 : Protocole de préparation des données




Figure 1 : Distribution du revenu mensuel avant et après transformation log1p

3.2 Statistiques descriptives

Variables numériques

Statistique	Age (années)	Revenu mensuel (HTG)
Effectif (n)	4 016	4 016
Moyenne	36,66	3 589
Médiane	34,00	2 756
Écart-type	16,02	3 445
Minimum / Maximum	15 / 79	0 / 29 110
Asymétrie (skewness)	0,734	2,117
Coefficient de variation	43,7 %	96,0 %

Tableau 7 : Statistiques descriptives des variables numériques

En effet, l'âge médian (34 ans) traduit une population cible jeune. La forte asymétrie du revenu (skewness=2,117) et son coefficient de variation élevé (96 %) signalent une très forte hétérogénéité économique, justifiant la transformation log1p avant modélisation. L'écart entre moyenne (3 589 HTG) et médiane (2 756 HTG) révèle l'effet de quelques hauts revenus sur la distribution.

Variables binaires - Taux d'accès

Variable	% Oui	Implication clé
Acte de naissance	93,9 %	Quasi-universel, non discriminant
CIN (Carte d'identité nationale)	65,3 %	34,7 % sans CIN entraîne un frein documentaire au crédit
Manque d'argent fréquent	63,3 %	Vulnérabilité très répandue
Possède un téléphone	61,0 %	Base potentielle pour mobile money
Membre d'une tontine (sòl)	40,6 %	Proxy de discipline d'épargne, transversal milieux
Épargne formelle	12,8 %	Très faible, opportunité de développement
Mobile money	12,0 %	Gap d'adoption : 61 % équipés vs 12 % utilisateurs (49 pp)
Crédit informel	7,0 %	Faible et uniforme , signal non discriminant

Tableau 8 : Taux d'accès aux services financiers




Figure 2 : Taux d'accès aux services financiers et documents

3.3 Analyse bivariable - Constats structurants

Revenu selon le secteur et le milieu

Dimension	Modalité	Revenu médian (HTG)	Écart vs médiane globale
Secteur	Emploi salarié formel	11 207	+307 %
	Commerce informel	4 028	+46 %
	Artisanat/Production	3 391	+23 %
	Agriculture/Élevage	1 875	-32 %

	Sans activité/Ménage	746	-73 %
Milieu	Urbain	3 380	+23 %
	Rural	1 540	-44 %

Tableau 9 — Revenu médian selon le secteur et le milieu




Figure 3 : Distribution du revenu mensuel selon le secteur d'activité

Comportements financiers selon le secteur

Secteur d'activité	% Tontine	% Mobile money	% Épargne formelle	% Manque argent
Commerce informel	49,0 %	12,3 %	13,6 %	61,3 %
Emploi salarié formel	32,6 %	18,2 %	31,6 %	43,6 %
Services/Transport	37,6 %	14,2 %	14,0 %	52,9 %
Artisanat/Production	32,3 %	10,9 %	10,7 %	65,1 %
Agriculture/Élevage	40,1 %	9,3 %	8,4 %	68,5 %
Sans activité/Ménage	39,6 %	12,2 %	10,4 %	75,0 %

Tableau 10 : Comportements financiers (% Oui) par secteur d'activité

On constate que les commerçants informels affichent le taux de tontine le plus élevé (49,0 %) , un signal fort d'une culture d'épargne collective active, directement exploitable comme proxy de solvabilité pour le microcrédit. Les salariés formels dominent sur l'épargne formelle (31,6 %) et le mobile money (18,2 %). Ces profils contrastés préfigurent les clusters qui émergeront lors de la modélisation.




Figure 4 : Comportements financiers par secteur d'activité (heatmap)

3.4 Tests statistiques

La non-normalité des variables numériques est confirmée par les tests de Shapiro-Wilk (Age : $W=0,938$, $p<10^{-37}$; Revenu : $W=0,808$, $p<10^{-55}$). Tous les tests de comparaison de groupes utilisent donc des méthodes non paramétriques.

Test	Variables	Statistique	p-valeur	Interprétation
Shapiro-Wilk	Age	$W=0,938$	$<10^{-37}$	Non normal, tests non paramétriques
Shapiro-Wilk	Revenu mensuel	$W=0,808$	$<10^{-55}$	Non normal, forte asymétrie confirmée
Mann-Whitney U	Revenu × Milieu	$U=2\,200\,678$	$<10^{-57}$	Revenu urbain 2,2× supérieur au rural ***
Mann-Whitney U	Revenu × Genre	$U=2\,027\,470$	$p=0,740$	Aucune différence significative - ns
Kruskal-Wallis	Revenu × Secteur	$H=2\,179,5$	≈ 0	Facteur le plus discriminant ***
Kruskal-Wallis	Revenu × Éducation	$H=69,4$	$<10^{-14}$	Gradient éducatif confirmé ***
Khi ² + V Cramér	Épargne × Inclusion	$V=0,638$	$<0,001$	Association forte ***
Khi ² + V Cramér	Tontine × Milieu	$V=0,003$	$p=0,872$	Tontine indépendante du milieu - ns
Spearman	Épargne ↔ Inclusion	$\rho=0,42$	$<0,001$	Corrélation modérée positive ***

Spearman	Revenu ↔ Manque argent	$\rho=-0,24$	$<0,001$	Corrélation négative - revenu protège ***
Spearman	Age ↔ Revenu	$\rho=0,00$	$p=0,925$	Absence de corrélation - ns

Tableau 11 : Synthèse des tests statistiques (***) : $p<0,001$ · ns : non significatif)




Figure 5 : Matrice de corrélation de Spearman - Variables retenues pour le clustering

3.5 Vérification des hypothèses analytiques

Hypothèse	Résultat EDA	Statut
H1 : Les membres de tontine + CIN présentent un profil favorable au microcrédit.	Tontine discrimine les secteurs ($V=0,115^{***}$). CIN corrèle avec l'éducation ($V=0,161^{***}$). Les deux variables seront structurantes dans le clustering.	Confirmée
H2 : Les commerçants informels urbains constituent le segment pré-bancabilisable prioritaire.	Tontine 49 %, revenu médian 4 028 HTG (+46 % vs médiane). Profil le plus actif financièrement parmi les secteurs informels.	Confirmée
H3 : Le milieu rural concentre les profils les plus éloignés du crédit.	Revenu rural 1 540 HTG vs 3 380 HTG urbain (Mann-Whitney $p<10^{-57}$). Mobile money rural 5,9 % vs 14,5 % urbain.	Confirmée
H4 : Le mobile money est corrélé à l'ouverture aux services formels.	Association modérée avec le téléphone ($V=0,295^{***}$) et le milieu ($V=0,121^{***}$). Gap d'adoption de 49 pp – potentiel non exploité.	Partiellement confirmée

Tableau 12 : Vérification des hypothèses analytiques initiales

4 - Méthodologie et choix du modèle

4.1 Type de problème et justification de l'approche

Le présent projet relève du clustering non supervisé : il n'existe pas de variable cible étiquetée à prédire, aucun individu n'a été préalablement classifié en « bancabilisable » ou non. L'objectif est de découvrir une structure latente dans les données, permettant d'identifier des groupes homogènes en interne et hétérogènes entre eux.

Justification de l'AFDM : le dataset est de nature mixte (2 variables numériques, 8 binaires, 3 ordinales, 1 nominale ce qui fait 17 colonnes après encodage). L'ACP classique ne s'applique qu'aux variables purement quantitatives. L'AFDM qui combine ACP pour les quantitatives et ACM pour les qualitatives, est la méthode de réduction de dimension rigoureusement adaptée aux données mixtes.

4.2 Réduction de dimension - AFDM

L'AFDM est implémentée en appliquant une ACP sur la matrice X_{scaled} ($4\,016 \times 17$), toutes variables correctement encodées et standardisées. Le critère de Kaiser ($\lambda > 1$) retient 9 composantes (68,4 % de variance). Pour capturer 85 % de la variance, 12 composantes sont retenues, compromis optimal entre parcimonie et information conservée. La matrice X_{pca} résultante est de dimension $4\,016 \times 12$.

Composante	Valeur propre (λ)	% Variance	% Cumulé	Interprétation
PC1	2,096	12,3 %	12,3 %	Intégration financière et revenus oppose bien intégrés aux vulnérables
PC2	1,647	9,7 %	22,0 %	Type d'activité oppose inactivité à agriculture
PC3	1,359	8,0 %	30,0 %	Commerce informel (loading 0,72) , profil sectoriel distinct
PC8	1,016	5,9 %	62,5 %	Crédit informel , composante quasi-pure (loading 0,83)
PC9	1,008	5,9 %	68,4 %	Âge , composante quasi-pure (loading 0,90)
PC10–PC12	0,91–0,96	16,5 %	85,0 %	Composantes retenues ($\lambda < 1$ mais information complémentaire)

Tableau 13 : Résultats AFDM - Valeurs propres et interprétation des axes (extrait)




Figure 6 : Scree plot (valeurs propres) et variance cumulée (12 composantes = 85,0 %)




Figure 7: Cercle des corrélations PC1 × PC2 - Variables par type (numérique, binaire, ordinale, one-hot)

4.3 Choix du nombre de clusters k

Six critères complémentaires sont mobilisés sur la matrice X_{pca} pour déterminer k. Aucun critère unique n'est décisif, la décision repose sur leur consensus.

Critère	k optimal	Valeur à k=6	Valeur à k=7	Décision
Méthode du coude (inertie $W(k)$)	5 ou 6	32 306	30 151	Inflexion visible entre k=5 et k=6
Silhouette $\bar{s}$ (maximiser)	7	0,268	0,271	Écart de 0,003, négligeable
Calinski-Harabasz (maximiser)	6	638,12	617,41	Pic net à k=6
Davies-Bouldin (minimiser)	7	1,463	1,389	Écart faible , k=6 acceptable
Gap statistic	Non conclusif	—	—	Croissante , structure diffuse
Dendrogramme CAH Ward	5 à 7	—	—	Pas de saut net , cohérent avec k=6

Tableau 14 : Critères de choix du nombre de clusters k

Le consensus repose sur Calinski-Harabasz (pic à $k=6$), la méthode du coude (inflexion à $k=5-6$) et l'interprétabilité métier : 6 profils sectoriels distincts identifiés en EDA correspondent naturellement à 6 clusters. La silhouette à $k=7$ (0,271) n'excède celle de $k=6$ (0,268) que de 0,003, un écart statistiquement négligeable ne justifiant pas la complexité supplémentaire.




Figure 8 : Critères de choix du nombre de clusters k ($k=2$ à 8)

4.4 Algorithmes appliqués et comparaison

Cinq algorithmes sont appliqués et comparés sur X_{pca} ($4\,016 \times 12$), évalués par trois métriques objectives : l'indice de silhouette $\bar{s}$, le score de Calinski-Harabasz (CH) et l'indice de Davies-Bouldin (DB). L'accord entre méthodes est mesuré par l'Adjusted Rand Index (ARI).

Algorithme	Silhouette	CH	DB	ARI vs K-means	Observation
K-means (k=6)	0,2683	638,12	1,4631	Référence	Modèle final, meilleur sur 3 métriques
CAH Ward (k=6)	0,2136	512,91	1,7639	0,7316	Validation indépendante, forte concordance
K-médoïdes PAM (k=6)	0,1421	347,43	2,0552	0,5525	Médoïdes réels interprétables, performance moindre
Mixte CAH + K-means	0,2683	638,12	1,4631	1,0000	Identique à K-means, convergence en 4 itérations
DBSCAN (eps=2,0)	0,2466	—	—	—	20 micro-clusters, structure globulaire confirmée

Tableau 15 — Comparaison des 5 algorithmes de clustering

Le K-means domine sur les trois métriques quantitatives. La méthode mixte produit exactement le même résultat (ARI=1,000) , elle valide que K-means avait déjà trouvé l'optimum global. La CAH confirme la structure (ARI=0,731). DBSCAN ne détecte pas de structure non sphérique validant le choix de K-means pour ce dataset.

5 - Fondements mathématiques mobilisés

5.1 Standardisation (Z-score)

Avant toute modélisation, chaque variable x_i est transformée selon : $\mathbf{z} = (\mathbf{x} - \boldsymbol{\mu}) / \boldsymbol{\sigma}$ où μ est la moyenne et σ l'écart-type de la variable sur l'ensemble d'entraînement. La standardisation garantit que toutes les variables contribuent équitablement à la distance euclidienne dans l'espace AFDM, indépendamment de leur unité ou de leur échelle initiale. Sans cette étape, le revenu (0–29 110 HTG) dominerait mécaniquement toutes les autres variables.

5.2 Analyse Factorielle de Données Mixtes (AFDM)

L'AFDM repose sur la décomposition en valeurs singulières (SVD) de la matrice $\mathbf{X}_{\text{scaled}}$. La matrice de covariance $\mathbf{C} = (1/n) \mathbf{X}^T \mathbf{X}$ est décomposée selon : $\mathbf{C} = \mathbf{V} \boldsymbol{\Lambda} \mathbf{V}^T$ où $\mathbf{V}$ est la matrice des vecteurs propres (loadings) et $\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$ la matrice des valeurs propres triées par ordre décroissant. Chaque valeur propre λ_k représente la variance capturée par la k -ième composante principale PC_k . La variance expliquée par PC_k est $\lambda_k / \sum \lambda_i$. Le critère de Kaiser ($\lambda_k > 1$) identifie les composantes apportant plus d'information qu'une variable standardisée isolée.

Paramètre	Valeur obtenue	Signification
p (variables en entrée)	17 colonnes	Après encodage et one-hot
Composantes Kaiser ($\lambda > 1$)	9	68,4 % de variance cumulée
Composantes retenues	12	85,0 % de variance cumulée
Variance PC1	12,3 % ($\lambda_1=2,096$)	Axe intégration financière + revenus
Variance PC3	8,0 % ($\lambda_3=1,359$)	Axe commerce informel (loading=0,72)
Dimension $\mathbf{X}_{\text{pca}}$	4 016 × 12	Matrice réduite pour clustering

Tableau 16 : Paramètres AFDM

5.3 Algorithme K-means

K-means minimise l'inertie intra-cluster (fonction objectif de Ward) : $\mathbf{W}(\mathbf{k}) = \sum_{j=1}^k \sum_{\mathbf{x} \in \mathbf{C}_j} \|\mathbf{x} - \boldsymbol{\mu}_j\|^2$ où μ_j est le centroïde du cluster $\mathbf{C}_j$ et $\|\cdot\|^2$ la distance euclidienne au carré. L'algorithme alterne entre deux étapes jusqu'à convergence : (1) affectation , chaque individu est assigné au centroïde le plus

proche ; (2) mise à jour , chaque centroïde est recalculé comme la moyenne de ses membres. L'initialisation k-means++ (Arthur & Vassilvitskii, 2007) choisit les centroïdes initiaux de manière probabiliste, réduisant le risque de convergence vers un minimum local.

Paramètre	Valeur retenue	Justification
n_clusters (k)	6	Consensus 6 critères , Calinski-Harabasz pic à k=6
init	k-means++	Initialisation probabiliste , meilleure convergence
n_init	50	50 initialisations différentes, retient la meilleure
max_iter	500	Convergence garantie même sur données complexes
random_state	42	Reproductibilité, même partition à chaque exécution

Tableau 17 : Paramètres du modèle K-means final

5.4 Classification Ascendante Hiérarchique (CAH) - Critère de Ward

La CAH Ward fusionne successivement les paires de clusters en minimisant l'augmentation d'inertie totale à chaque fusion. Le coût de fusion entre clusters C_a et C_b est :

$\Delta W(C_a, C_b) = (n_a \cdot n_b) / (n_a + n_b) \cdot \|\mu_a - \mu_b\|^2$. La CAH est déterministe, elle produit toujours la même partition pour les mêmes données, contrairement à K-means. Elle sert ici de validation indépendante (ARI vs K-means = 0,731) et d'initialisation pour la méthode mixte.

5.5 Métriques d'évaluation du clustering

Métrique	Formule	Optimum	Valeur obtenue
Silhouette $\bar{s}$	$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$ $a(i)$ =dist. moy. intra-cluster $b(i)$ =dist. moy. cluster voisin le plus proche	1	0,2683 (k=6)
Calinski-Harabasz (CH)	$CH = [\text{tr}(B_k)/(k-1)] / [\text{tr}(W_k)/(n-k)]$ trace de la dispersion inter/intra-cluster	max	638,12
Davies-Bouldin (DB)	$DB = (1/k) \sum_i \max_{j \neq i} [(s_i + s_j) / d(c_i, c_j)]$ s_i =dispersion cluster i $d(c_i, c_j)$ =dist. centroïdes	min	1,4631
Adjusted Rand Index (ARI)	$ARI = (RI - E[RI]) / (\max(RI) - E[RI])$ corrigé du hasard — $ARI=1$: partitions identiques	1	1,0000 (Bootstrap 50 runs)
Eta ² (Kruskal-Wallis)	$\eta^2 = (H - k + 1) / (n - k)$ proportion de variance inter-clusters	1 (max)	0,5423 (Revenu)

Tableau 18 : Métriques d'évaluation mobilisées avec formules et valeurs obtenues

6- Analyse OLAP et tableau de bord Power BI

Modèle OLAP- Faits, mesures et dimensions

Élément	Contenu
Fait central	Individu de la population cible (ménage haïtien exclu du crédit formel)
Mesures (10 KPI)	N individus · Revenu médian · % Exclus financièrement · % CIN · % Tontine · % Mobile money · % Épargne formelle · % Manque argent · Gap mobile money · Score priorité ciblage (0–100)
Dimension géographique	Département (10 modalités) · Milieu (Urbain/Rural)
Dimension économique	Secteur d'activité (6) · Niveau d'éducation (4)
Dimension financière	Niveau d'inclusion financière (4 niveaux)
Tables agrégées	11 fichiers CSV : par département, milieu, secteur, éducation, inclusion, genre, âge et combinaisons croisées
Outil	Power BI Desktop : 4 pages thématiques avec filtres croisés interactifs (slicers)

Tableau 12 bis — Modèle OLAP — Faits, mesures et dimensions

Tableau de bord - 4 pages thématiques

Page	Titre	Visuels principaux	Filtres
1	Vue générale	6 cartes KPI · Niveau d'inclusion · Répartition sectorielle · Taux accès services	Département · Milieu · Genre
2	Analyse géographique	Revenu médian · % CIN · % Tontine · % Mobile money par département · Tableau récapitulatif	Milieu (Urbain/Rural)
3	Profils comportementaux	Tontine/Mobile money × Genre et Milieu · Revenu médian × Secteur · Comportements × Secteur · Planification financière	Département · Milieu
4	Ciblage microcrédit	Score de priorité par département · Gap mobile money · Tableau de ciblage synthétique	Milieu (Rural/Urbain)

Tableau 19 : Architecture du dashboard Power BI (4 pages)

Score de ciblage microcrédit par département (filtre Rural)

Un score composite (0–100) est calculé pour chaque département selon six composantes pondérées :

$$\text{Score} = (\% \text{ Tontine} \times 0,20) + (\% \text{ CIN} \times 0,20) + (\text{Revenu normalisé} \times 0,20) + (\% \text{ Exclusion} \times 0,15) + (\% \text{ Manque argent} \times 0,15) + (\% \text{ Téléphone} \times 0,10)$$

Rang	Département	Score /100	Rev. médian (HTG)	% Tontine	% CIN	% Exclus	Recommandation
1	Nippes	57,0	1 769	41,3 %	52,3 %	63,3 %	Priorité rurale , besoins + potentiel d'adoption
2	Nord-Est	56,5	1 794	47,1 %	41,2 %	70,6 %	Fort potentiel tontine malgré CIN faible
3	Centre	54,9	1 747	41,9 %	56,4 %	57,6 %	Bon équilibre documentation + exclusion
4	Grand-Anse	46,2	1 651	34,6 %	56,2 %	56,9 %	CIN correct mais tontine faible
5	Aire Métro	45,3	1 633	41,3 %	58,1 %	43,2 %	Meilleur score global (hors filtre Rural)
...	...	...	...	...	...	...	...
10	Nord-Ouest	38,1	1 540	36,4 %	46,6 %	67,1 %	Zone vulnérabilité — programme BRH prioritaire

Tableau 20 : Score de priorité microcrédit par département (filtre Rural)

Constat clé : Le classement rural diffère du classement global. Nippes et Nord-Est arrivent en tête, non pas parce qu'ils sont les plus riches, mais parce qu'ils combinent un taux d'exclusion financière élevé (besoin non couvert) et des comportements d'épargne informelle actifs (potentiel d'adoption). Le Nord-Ouest, malgré son taux de manque d'argent le plus élevé (73,9 %), se retrouve en dernière position en raison de son faible taux de CIN (46,6 %) et de tontine (36,4 %), un frein structurel à l'accès au crédit.

Figure 9: Indicateurs par département (filtre Rural)

Figure 10 : Score de priorité par département (filtre Rural)

7 - Résultats et évaluation

7.1 Performance du modèle final

Métrique	Valeur	Interprétation
Silhouette globale $\bar{s}$	0,2683	Correct pour données mixtes encodées, dans le tiers supérieur des benchmarks FinScope (0,20–0,35)
Calinski-Harabasz	638,12	Meilleur score parmi les 5 méthodes, clusters bien séparés et compacts
Davies-Bouldin	1,4631	Meilleur score parmi les 5 méthodes, faible chevauchement inter-clusters
Inertie intra $W(k=6)$	32 306,46	44,3 % de la variance totale expliquée par les clusters
Inertie inter	25 704,98 (44,3 %)	Part de variance capturée par la segmentation
Individus ambigus $s < 0$	0 (0,0 %)	Aucun individu mal assigné, résultat exceptionnel
Individus frontières $0 \leq s < 0,10$	26 (0,6 %)	Profil mixtes entre clusters proches, proportion négligeable
ARI Bootstrap (50 runs)	1,0000 · std=0,0000	Stabilité parfaite, même partition à chaque initialisation

Tableau 19 : Métriques de performance du modèle K-means $k=6$




Figure 9: $ARI=1,000 \cdot std=0,000$ sur 50 runs, clustering déterministe

En effet, un $ARI=1,000$ avec $std=0,000$ sur 50 runs indépendants signifie que les 6 clusters sont retrouvés identiquement quelle que soit l'initialisation. Cette stabilité parfaite, rare en pratique, confirme que les frontières entre segments sont suffisamment nettes dans l'espace AFDM pour qu'aucun minimum local ne puisse les altérer. Elle invalide tout soupçon d'artefact algorithmique.

7.2 Analyse de silhouette par segment

Segment	Silhouette moy.	Std	Min	Max	Interprétation
Artisans	0,316	0,067	0,121	0,445	Cluster le plus compact, frontières très nettes
Salariés formels	0,314	0,074	0,087	0,436	Profil très distinct, revenu élevé crée une séparation nette
Prestataires de services	0,278	0,053	0,127	0,372	Bien séparé, revenu intermédiaire distinctif
Agriculteurs vulnérables	0,273	0,069	0,025	0,404	Correct, groupe large mais cohérent
Ménages sans revenus	0,251	0,073	0,044	0,415	Plus diffus, frontière floue avec les Agriculteurs
Commerçants informels	0,235	0,050	0,086	0,332	Moins compact, hétérogénéité interne du secteur

Tableau 20 : Analyse de silhouette individuelle par segment




Figure 10 : diagramme par cluster (gauche) et distribution violon (droite)

7.3 Pouvoir discriminant des variables

Le test de Kruskal-Wallis mesure si les distributions diffèrent significativement entre les k=6 clusters pour chaque variable. L'effet size η^2 quantifie la proportion de variance inter-clusters expliquée.

Rang	Variable	Statistique H	p-valeur	Eta ²	Interprétation
1	Revenu_Mensuel_HTG	2 179,47	$<10^{-100}$	0,5423	Très fort, 54 % de la variance entre clusters
2	Secteur_Activite	Chi ² =20 080	$<10^{-100}$	V=1,000	Très fort, association parfaite secteur/cluster
3	Niveau_Inclusion_Financiere	345,75	$<10^{-72}$	0,0850	Fort, sépare bancarisés des exclus
4	Manque_Argent_Frequent	125,72	$<10^{-25}$	0,0301	Modéré, différencie vulnérables (75%) des stables (44%)
5	Epargne_Formelle	122,58	$<10^{-24}$	0,0293	Modéré, sépare Salariés (32%) des autres (<15%)
6	Niveau_Education	91,71	$<10^{-17}$	0,0216	Modéré, gradient éducatif entre segments
7	Membre_Tontine_Sol	53,12	$<10^{-9}$	0,0120	Modéré, Commerçants (49%) vs Artisans (32%)
8–10	CIN, Mobile money, Planification	15–26	$<0,01$	0,003–0,005	Faible mais significatif
11–12	Age, Credit_Informel	1,39–1,83	$p>0,80$	≈ 0	Non discriminants, à retirer dans v2

Tableau 21 : Pouvoir discriminant des variables - Kruskal-Wallis et Eta²




Figure 11 : Pouvoir discriminant des variables (Eta²) - Kruskal-Wallis

Test de robustesse, Segmentation sans revenu : K-means k=6 appliqué sans Revenu_log produit une silhouette de 0,2686 (vs 0,2683 avec revenu) et un ARI=0,9969 vs le modèle complet. Ce résultat crucial confirme que la segmentation reflète une structure multidimensionnelle réelle non un simple classement de revenus. Les comportements financiers (tontine, mobile money, épargne) et le secteur d'activité suffisent à reproduire quasi-parfaitement les 6 clusters.

7.4 Les six segments identifiés

Cluster	Segment	n	%	Rev. médian	Score	Silhouette	Statut
3	Salariés formels	307	7,6 %	11 207 HTG	80,3/100	0,314	☐ Prioritaire
5	Commerçants informels	1 026	25,5 %	4 028 HTG	51,3/100	0,235	☐ Secondaire
1	Prestataires de services	529	13,2 %	5 320 HTG	45,1/100	0,278	☐ Secondaire
4	Ménages sans revenus	599	14,9 %	746 HTG	26,4/100	0,251	☐ Non prioritaire
2	Artisans	439	10,9 %	3 391 HTG	24,2/100	0,316	☐ Non prioritaire
0	Agriculteurs vulnérables	1 116	27,8 %	1 875 HTG	12,6/100	0,273	☐ Non prioritaire

Tableau 22 : Vue d'ensemble des 6 segments (score = priorité microcrédit sur 100)




Figure 12 : Score de priorité microcrédit par segment (0–100)




Figure 13 : Profils des 6 segments- K-means k=6 (valeur réelle + écart standardisé)

Segment 3 - Salariés formels (Score 80,3/100, Prioritaire)

Indicateur	Valeur segment	Médiane globale	Écart
Revenu médian	11 207 HTG	2 756 HTG	+307 %
Épargne formelle	32 %	12,8 %	+19 pp
CIN	72 %	65,3 %	+7 pp
Mobile money	18 %	12,0 %	+6 pp
Manque argent	44 %	63,3 %	−19 pp
Niveau d'inclusion	2,14/3	—	Quasi-bancarisé

Ce segment possède toutes les caractéristiques requises par une IMF. Un revenu régulier élevé (capacité de remboursement), CIN (éligibilité documentaire), épargne formelle (discipline financière prouvée) et mobile money (remboursement numérique possible). Produit recommandé : prêt personnel ou professionnel de 15 000 à 50 000 HTG, remboursement par virement mensuel.

Segment 5 — Commerçants informels (Score 51,3/100, Secondaire)

Indicateur	Valeur segment	Médiane globale	Écart
Revenu médian	4 028 HTG	2 756 HTG	+46 %
Tontine	49,0 %	40,6 %	+8,4 pp- le plus élevé de tous les segments

CIN	67 %	65,3 %	+2 pp
Mobile money	12 %	12,0 %	≈ médiane
Manque argent	61 %	63,3 %	-2 pp
Effectif	1 026 (25,5 %)	—	2 ^e groupe en taille

Le taux de tontine de 49 % , le plus élevé de tous les clusters,est le signal analytique le plus fort : participer à un sòl implique une discipline d'épargne régulière et une réputation de fiabilité financière au sein de la communauté, substituant efficacement les garanties formelles. Ce segment est le candidat idéal pour un microcrédit groupé adossé aux tontines existantes (5 000–20 000 HTG, remboursement hebdomadaire).

Segment 1 - Prestataires de services (Score 45,1/100 · □ Secondaire)

Revenu médian 5 320 HTG (+93 % vs médiane globale), mobile money 14 % (le 2^e plus élevé après salariés formels). **Segment à fort potentiel pour les produits de mobile lending** (crédit numérique décaissé et remboursé via Digicel/Natcom, 3 000–15 000 HTG).

Segments non prioritaires - Ménages sans revenus, Artisans, Agriculteurs vulnérables

Segment	Caractéristique principale	Recommandation
Ménages sans revenus (14,9 %)	Revenu médian 746 HTG · Manque argent 75 %	Épargne mobile money d'abord — crédit contre-indiqué à court terme
Artisans (10,9 %)	Revenu 3 391 HTG · Tontine 32 % (le plus faible parmi actifs)	Sensibilisation aux mécanismes collectifs → crédit équipement à 6 mois
Agriculteurs vulnérables (27,8 %)	CIN 59 % (le plus faible) · Exclusion financière 80 %	Programme BRH : identification nationale + assurance agricole avant crédit

Tableau 23 : Caractéristiques et recommandations pour les segments non prioritaires

7.5 Répartition géographique des segments

Département	% Agric. vuln.	% Comm. inform.	% Salariés form.	% Prestat. serv.	% Ménages s.r.	% Artisans
Aire Métropolitaine	14,0	29,0	11,8	15,9	16,9	12,3
Nippes	46,4	22,9	1,7	7,8	12,8	8,4
Grand-Anse	45,8	21,9	3,5	9,0	11,4	8,5
Nord-Ouest	44,1	19,1	1,5	6,6	15,4	13,2
Centre	40,9	21,0	4,6	10,0	13,2	10,3
Nord-Est	31,5	24,3	5,5	14,4	13,8	10,5
Nord	31,3	25,4	6,9	12,5	14,2	9,7
Artibonite	33,2	22,9	5,6	11,9	14,9	11,5
Sud	32,7	24,5	6,5	13,1	10,6	12,5
Ouest (reste)	29,9	26,4	6,4	14,3	16,9	6,1

Tableau 24 : Répartition des segments par département (% de la population du département)

On distingue trois zones distinctes émergent : (1) Zone à fort potentiel commercial en prenant Aire Métropolitaine (29 % commerçants, 11,8 % salariés) et Ouest reste, marché prioritaire pour les IMF ; (2) Zone à potentiel modéré en prenant Nord, Sud, Nord-Est, Artibonite ; (3) Zone de vulnérabilité prioritaire BRH en prenant Nippes (46,4 % agriculteurs), Grand-Anse (45,8 %), Nord-Ouest (44,1 %), Centre (40,9 %), programmes publics d'inclusion requis avant tout crédit commercial.

8- Interprétation, limites et discussion critique

8.1 Ce qu'apprennent les résultats

Les six segments identifiés ne sont pas des artéfacts algorithmiques, ils sont confirmés par trois méthodes indépendantes (CAH ARI=0,731 ; Méthode mixte ARI=1,000 ; Bootstrap 50 runs ARI=1,000), par des tests statistiques rigoureux (Kruskal-Wallis H=2179,5 pour le revenu, $p \approx 0$) et par la robustesse à la suppression de la variable dominante (ARI sans revenu=0,997). La segmentation reflète une structure réelle de la société haïtienne.

Question analytique	Réponse apportée
Q1- Quelles variables discriminent le mieux ?	Le revenu mensuel ($Eta^2=0,542$) et le secteur d'activité ($V=1,000$) dominant. Le niveau d'inclusion financière ($Eta^2=0,085$) arrive en 3 ^e position. L'âge et le crédit informel sont non discriminants ($Eta^2 \approx 0$).
Q2- Existe-t-il un segment pré-bancabilisable ?	Oui, deux segments répondent à ce critère. Salariés formels (score 80,3, $n=307$) : profil le plus bancabilisable. Commerçants informels (score 51,3, $n=1\ 026$) : cible stratégique prioritaire en volume (tontine 49 %).
Q3- La géographie structure-t-elle les profils ?	Oui, fortement. Aire Métropolitaine = 29 % commerçants + 11,8 % salariés. Nippes, Grand-Anse, Nord-Ouest = 44–46 % d'agriculteurs vulnérables. Gradient rural/urbain confirmé (Mann-Whitney $p < 10^{-57}$).
Q4- Quelle méthode est la plus robuste ?	K-means $k=6$, meilleur sur 3 métriques, stabilité parfaite (ARI Bootstrap=1,000), validation CAH (ARI=0,731), structure multidimensionnelle confirmée.

Tableau 25 : Réponses aux questions analytiques initiales

On constate que les Artisans présentent paradoxalement la silhouette la plus élevée (0,316- cluster le plus compact) mais le deuxième score de priorité le plus faible (24,2/100). Ce paradoxe s'explique : leur compacité tient à l'homogénéité de leurs faibles indicateurs financiers comportementaux (tontine 32 %- le plus bas des segments actifs, mobile money 11 %, épargne 11 %), non à une forte bancabilisation. C'est un groupe culturellement éloigné des mécanismes financiers collectifs malgré un revenu correct (3 391 HTG).

8.2 Utilité pratique du modèle

Le modèle est directement opérationnel. Le pipeline de prédiction (scaler.pkl + pca_afdm.pkl + kmeans_final.pkl + predict.py) a été testé sur 100 individus aléatoires avec un accord de 100 %

avec les labels originaux. Dès réception des microdonnées officielles FinScope 2018 de la BRH, l'application se réduit à quatre lignes de code Python, produisant instantanément le profil de segment de chaque ménage.

Utilisateur	Valeur opérationnelle concrète
IMF souhaitant lancer un produit microcrédit	Identification immédiate des 1 333 individus des segments prioritaires (salariés + commerçants = 33,1 % de la population cible), priorisation de la prospection commerciale par zone géographique et profil
BRH - Stratégie nationale d'inclusion	Cartographie des 3 zones : (1) potentiel commercial (Aire Métro, Ouest) ; (2) potentiel modéré (Nord, Sud, Artibonite) ; (3) priorité politique publique (Nippes, Grand-Anse, Nord-Ouest, Centre)
Fintechs / mobile money	Ciblage des zones à fort gap d'adoption (Nord-Est 44 pp, Nord 42 pp), déploiement du mobile lending auprès des prestataires de services (mobile money 14 %)
Chercheurs et décideurs	Première segmentation non supervisée des ménages haïtiens exclus du crédit sur données FinScope, base comparative pour les mises à jour biannuelles

Tableau 26 : Valeur opérationnelle du modèle par utilisateur

8.3 Limites identifiées

Code	Limite	Nature	Impact	Mesure prise / Perspective
L1	Dataset synthétique , corrélations partiellement simulées	Méthodologique	Moyen	Pipeline prêt pour microdonnées BRH réelles. Résultats à valider lors de la réception des données officielles.
L2	Sous-représentation rurale (29,3 % vs ~45 % réel)	Biais de collecte	Moyen	Segments ruraux sous-estimés en taille. Recommandation : appliquer Poids_Sondage dans la version 2.
L3	Données de 2018, contexte post-COVID, inflation, instabilité non reflétés	Temporelle	Moyen	Croiser avec FINDEX 2021. Mise à jour biannuelle recommandée.
L4	Age et Crédit_Informel non discriminants ($Eta^2 \approx 0$)	Sélection variables	Faible	Variables conservées pour la description mais à retirer dans v2 , réduction à 10 variables.
L5	V de Cramér Secteur_Activite = 1,000, circularité	Méthodologique	Faible	Limite documentée : le one-hot encoding du secteur a participé au clustering. Résultat attendu, non un biais.

L6	Silhouette modérée (0,268), frontières floues entre certains clusters	Qualité modèle	Faible	Normale pour données mixtes encodées. Tous les clusters restent interprétables métier.
L7	Absence de données longitudinales, associations, pas de causalité	Inférence	Faible	Une étude longitudinale permettrait de mesurer l'adoption réelle du microcrédit par segment.

Tableau 27 : Limites et biais identifiés avec mesures correctives

8.4 Discussion critique

La tontine comme proxy de bancabilité, validité et limites

L'utilisation de la participation aux tontines comme proxy de solvabilité repose sur un fondement empirique solide : les sòl haïtiens impliquent une discipline d'épargne régulière, une responsabilité collective et une pénalité en cas de défaut de versement, mécanismes analogues aux garanties demandées par les IMF. Cependant, deux nuances s'imposent. Premièrement, la tontine est un proxy indirect, un individu peut participer à un sòl sans disposer d'une capacité réelle de remboursement d'un crédit formel plus élevé. Deuxièmement, le taux de tontine est quasi-identique entre milieu urbain (40,5 %) et rural (40,8 %), la variable discrimine les secteurs d'activité mais pas les milieux, ce qui en limite la portée géographique comme critère de ciblage.

Domination du revenu, structure réelle ou artéfact ?

Le revenu présente un Eta^2 de 0,542, il explique à lui seul 54 % de la variance inter-clusters. Ce résultat soulève une question légitime : la segmentation ne reflète-t-elle que des classes de revenus ? Le test de robustesse y répond sans ambiguïté. L'ARI entre la segmentation complète et la segmentation sans revenu est de 0,9969, les 6 clusters sont quasi-identiquement retrouvés par les seuls comportements financiers et le secteur d'activité. La structure est donc bien multidimensionnelle : le revenu est la variable la plus discriminante, mais il n'est pas le seul facteur structurant.

Comparaison avec la littérature

Les études de segmentation sur données FinScope en Afrique subsaharienne (Bila, 2015 ; Umuhoza et al., 2020) rapportent des silhouettes comprises entre 0,20 et 0,35 pour des

segmentations à 4–7 clusters sur données mixtes similaires. Notre silhouette de 0,268 se situe dans le tiers supérieur de cette fourchette, attestant d'une segmentation de qualité solide compte tenu de la nature diffuse des données socio-économiques. La stabilité Bootstrap (ARI=1,000) surpasse les résultats typiquement reportés dans la littérature (ARI moyen de 0,85–0,95 sur des données comparables).

9- Considérations éthiques et pratiques

9.1 Confidentialité et protection des données

L'ensemble du projet repose sur un dataset synthétique, aucune donnée individuelle réelle n'est utilisée. Les microdonnées officielles FinScope 2018, dont la demande d'accès académique est en cours auprès de la BRH, sont soumises au secret statistique et ne peuvent être publiées ou partagées sans autorisation explicite de la BRH et de FinMark Trust. Le pipeline de prédiction est conçu pour fonctionner sur des données anonymisées, le script `predict.py` ne requiert aucun identifiant nominal pour produire les segments.

Précaution opérationnelle : lors du déploiement sur données réelles, les résultats de segmentation (labels de clusters) doivent être traités comme des données sensibles. Un individu classé en 'segment non prioritaire' ne doit pas se voir automatiquement refuser un crédit, car la segmentation est un outil d'aide à la décision, non un critère d'exclusion automatique.

9.2 Biais potentiels et risques de discrimination

Biais potentiel	Description	Précaution recommandée
Biais de sous-représentation rurale	Le milieu rural est sous-représenté (29,3 % vs ~45 % réel). Les segments ruraux, notamment les Agriculteurs vulnérables (27,8 %) sont probablement sous-estimés en taille réelle.	Appliquer les coefficients Poids_Sondage pour redresser la représentativité avant tout usage décisionnel sur les données officielles.
Biais de genre	Le modèle ne distingue pas les hommes et les femmes au niveau des clusters (genre non discriminant dans les tests). Les femmes commerçantes informelles qui participent davantage aux tontines (45,6 % vs 35,3 %) , peuvent être sous-représentées dans les segments les mieux scorés.	Produire des analyses de sous-groupes par genre sur les données officielles. Concevoir des produits microcrédit spécifiquement adaptés aux femmes commerçantes (ex: crédit solidaire féminin).
Biais temporel	Les données de 2018 ne reflètent pas le contexte post-COVID, l'hyperinflation de 2022–2024 ni l'insécurité généralisée qui ont profondément modifié les comportements financiers haïtiens.	Présenter explicitement ce biais lors de tout usage décisionnel. Croiser avec FINDEX 2021 pour une mise en perspective contemporaine.

Risque de discrimination par secteur	La variable Secteur_Activite structure fortement les clusters (V=1,000). Un usage commercial pourrait conduire à des refus systématiques pour les agriculteurs ou ménages sans activité, indépendamment de leur situation individuelle.	Interdire l'usage du segment comme critère d'exclusion automatique. Maintenir une évaluation individuelle pour tout dossier de crédit, le segment ne servant qu'à orienter la prospection initiale.
--------------------------------------	---	---

Tableau 28 : Biais potentiels et précautions d'usage

9.3 Conditions d'usage responsable

Condition	Description
Transparence algorithmique	Les IMF utilisant ce modèle doivent être en mesure d'expliquer à un demandeur de crédit les raisons de son classement dans un segment donné, notamment les variables qui ont le plus contribué à son profil.
Non-automaticité	La segmentation est un outil de priorisation commerciale, non un système de scoring de crédit automatique. Toute décision d'octroi ou de refus doit impliquer un conseiller humain.
Mise à jour régulière	Le modèle doit être réentraîné tous les deux ans au minimum sur des données actualisées, sous peine d'obsolescence. Le pipeline predict.py facilite cette mise à jour, seuls les fichiers .pkl doivent être recalculés.
Validation externe	Avant tout déploiement commercial, le modèle doit être validé sur les microdonnées officielles FinScope 2018 (BRH) et sur un échantillon de nouveaux demandeurs de crédit pour mesurer la corrélation entre segment et remboursement réel.
Inclusion des non-prioritaires	Les segments classés 'non prioritaires' (Agriculteurs, Ménages sans revenus) ne doivent pas être ignorés, ils identifient des populations nécessitant des programmes d'inclusion différents (épargne, assurance, identification), pas une exclusion.

Tableau 29 : Conditions d'usage responsable du modèle de segmentation

Recommandations

Pour les IMF et banques commerciales

Segment cible	Produit recommandé	Montant	Remboursement	Justification clé
Salariés formels	Prêt personnel / professionnel	15 000–50 000 HTG	Virement mensuel	Revenu 11 207 HTG · Épargne formelle 32 % · Score 80,3
Commerçants informels	Microcrédit groupé (tontines)	5 000–20 000 HTG	Hebdomadaire / bi-mensuel	Tontine 49 % · Revenu 4 028 HTG · Score 51,3
Prestataires de services	Crédit numérique mobile	3 000–15 000 HTG	Via mobile money	Mobile money 14 % · Revenu 5 320 HTG · Score 45,1
Artisans	Crédit équipement (après sensibilisation)	10 000–30 000 HTG	Mensuel post-6 mois	Revenu correct, faible adoption mécanismes financiers
Ménages sans revenus	Épargne mobile money, pas de crédit	—	Dépôt régulier	Revenu 746 HTG · Manque argent 75 %, risque défaut élevé
Agriculteurs vulnérables	Programme BRH, identification + assurance	—	—	CIN 59 % · Exclusion 80 %, accompagnement requis

Tableau 30 : Recommandations produit par segment

Pour la Banque de la République d'Haïti (BRH)

Recommandation	Justification	Horizon
Accélérer le programme CIN dans les zones rurales, objectif 70 % (actuellement 59 % chez les agriculteurs)	CIN = frein documentaire n°1 au crédit. Chaque point de CIN supplémentaire élargit le bassin de clientèle potentiel des IMF.	Court terme (2026-2027)
Déployer l'assurance agricole avant tout programme de microcrédit agricole	Agriculteurs vulnérables : revenu médian 1 875 HTG, manque argent 69 %. Sans filet de sécurité, tout crédit agricole présente un risque de défaut systémique en cas d'aléa climatique.	Moyen terme (2026-2028)

Stimuler l'adoption du mobile money, réduire le gap de 49 pp à moins de 30 pp d'ici 2028	61 % équipés de téléphone vs 12 % utilisateurs du mobile money. Infrastructure existante sous-exploitée, réglementation branchless banking favorable requise.	Moyen terme (2027-2028)
Instaurer un observatoire de l'inclusion financière avec segmentation biannuelle	Les données de 2018 ne reflètent plus le contexte actuel. Une mise à jour régulière sur données FinScope ou FINDEX permettrait d'ajuster les politiques.	Long terme (annuel)

Tableau 31 : Recommandations pour la BRH

Conclusion

Ce projet a produit la première segmentation non supervisée des ménages haïtiens exclus du crédit formel sur données FinScope, en mobilisant une démarche analytique rigoureuse en huit étapes. L'AFDM a réduit 17 variables mixtes en 12 composantes principales (85 % de variance), sur lesquelles cinq algorithmes ont été comparés. Le modèle K-means $k=6$, retenu sur consensus de six critères, identifie six segments distincts validés statistiquement par ARI Bootstrap=1,000 sur 50 runs et confirmés par la CAH (ARI=0,731) et la méthode mixte (ARI=1,000).

Les résultats répondent directement aux questions analytiques initiales. Le revenu et le secteur d'activité sont les deux variables les plus discriminantes. Deux segments constituent les cibles prioritaires pour une offre de microcrédit : les salariés formels (7,6 %, score 80,3/100) et les commerçants informels (25,5 %, score 51,3/100), soit 33,1 % de la population cible. La localisation géographique structure fortement les profils, avec l'Aire Métropolitaine comme marché prioritaire et Nippes, Grand-Anse, Nord-Ouest comme zones de vulnérabilité nécessitant des politiques publiques d'inclusion.

Contribution principale : le pipeline de prédiction (predict.py) est opérationnel et validé à 100 %. Dès réception des microdonnées officielles FinScope 2018 de la BRH, la segmentation peut être appliquée en quelques minutes, transformant ce projet académique en outil décisionnel directement utilisable par les institutions financières haïtiennes.

Références bibliographiques

Sources institutionnelles

- Banque de la République d'Haïti (BRH), DAI Finance Inclusive, & FinMark Trust. (2019, avril). FinScope Consumer Haïti 2018 : Résultats de l'enquête nationale sur l'accès aux services financiers. Port-au-Prince : BRH.
- Banque Mondiale. (2022). Global Financial Inclusion Database (FINDEX) 2021. Washington D.C.
<https://www.worldbank.org/en/publication/globalfindex>
- Banque de la République d'Haïti. (2020). Plan National d'Éducation Financière (PNEF) 2020-2025. Port-au-Prince : BRH.

Méthodes statistiques et apprentissage automatique

- Arthur, D., & Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms, 1027-1035.
- Calinski, T., & Harabasz, J. (1974). A dendrite method for cluster analysis. Communications in Statistics, 3(1), 1-27.
- Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1(2), 224-227.
- Hubert, L., & Arabie, P. (1985). Comparing partitions. Journal of Classification, 2(1), 193-218.
- Pagès, J. (2014). Multiple Factor Analysis by Example Using R. CRC Press / Chapman & Hall.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53-65.

Inclusion financière et microfinance

- Armendáriz, B., & Morduch, J. (2010). The Economics of Microfinance (2nd ed.). MIT Press.
- Bila, S. (2015). FinScope as a tool for measuring financial inclusion across countries. FinMark Trust Working Paper.
- Demirgüç-Kunt, A., Klapper, L., Singer, D., Ansar, S., & Hess, J. (2022). The Global Findex Database 2021. Banque Mondiale.
- Morduch, J. (1999). The microfinance promise. Journal of Economic Literature, 37(4), 1569-1614.
- Umuhzo, D., et al. (2020). Credit card customer segmentation using machine learning techniques. African Journal of Business Management, 14(3), 78-91.

Annexes

Annexe A- Dictionnaire complet des 34 variables

Variable	Type	Modalités / Domaine	Description	Rôle
ID_Individu	Identifiant	1 – 4 269	Identifiant unique de l'individu	Clé primaire
Departement	Catégorielle	10 modalités	Département de résidence	Géographique
Milieu	Binaire	Urbain / Rural	Milieu de résidence	Géographique
Genre	Binaire	Homme / Femme	Genre de l'individu	Démographique
Age	Numérique	15 – 79 ans	Âge en années révolues	Démographique
Tranche_Age	Catégorielle	15-17, 18-24, 25-34, 35-44, 45-60, 60+	Tranche d'âge	Démographique
Niveau_Education	Ordinale	4 niveaux (0→3)	Plus haut niveau d'éducation atteint	Capital humain
Secteur_Activite	Nominale	6 secteurs	Secteur d'activité principal	Économique
Revenu_Mensuel_HTG	Numérique	0 – 29 110 HTG	Revenu mensuel déclaré	Économique
Possede_Telephone	Binaire	Oui / Non	Possession d'un téléphone (mobile)	Numérique
Possede_Smartphone	Binaire	Oui / Non	Possession d'un smartphone	Numérique
Acces_Internet	Binaire	Oui / Non	Accès à Internet (domicile ou mobile)	Numérique
Acte_Naissance	Binaire	Oui / Non	Possession d'un acte de naissance	Documentaire
CIN_Carte_Identite	Binaire	Oui / Non	Possession de la Carte d'Identité Nationale	Documentaire
NIF_Matricule_Fiscal	Binaire	Oui / Non	Possession d'un Numéro	Documentaire

			d'Identification Fiscale	
Titre_Propriete	Binaire	Oui / Non	Possession d'un titre de propriété	Documentaire
Statut_Logement	Catégorielle	5 modalités	Statut du logement (propriétaire, locataire...)	Social
Source_Energie	Catégorielle	5 modalités	Source principale d'énergie du ménage	Social
Implique_Agriculture	Binaire	Oui / Non	Implication dans une activité agricole	Économique
Niveau_Inclusion_Financiere	Ordinale	4 niveaux (0→3)	Niveau d'intégration dans le système financier	Financier
Compte_Bancaire	Binaire	Oui / Non	Possession d'un compte bancaire	Financier
Credit_Formel	Binaire	Oui / Non	Accès à un crédit formel	Financier
Credit_Informel	Binaire	Oui / Non	Accès à un crédit informel	Financier
Epargne_Formelle	Binaire	Oui / Non	Épargne dans une institution formelle	Financier
Membre_Tontine_Sol	Binaire	Oui / Non	Membre d'une tontine (sòl)	Financier
Mobile_Money	Binaire	Oui / Non	Usage du mobile money	Financier
Planification_Financiere	Ordinale	4 niveaux (0→3)	Fréquence de planification financière	Comportemental
Controle_Depenses	Catégorielle	4 modalités	Contrôle des dépenses du ménage	Comportemental
Manque_Argent_Frequent	Binaire	Oui / Non	Manque d'argent fréquent au cours des 12 derniers mois	Vulnérabilité
Raison_Principale_Manque_Argent	Catégorielle	7 modalités	Raison principale du manque d'argent	Vulnérabilité

Besoin_Education_Financiere	Catégorielle	5 modalités	Besoin en éducation financière exprimé	Comportemental
Jamais_Eu_Credit_Formel	Binaire	Oui / Non	N'a jamais eu accès au crédit formel	Filtre / Cible
Montant_Credit_Formel_HTG	Numérique	0 HTG (pop. cible)	Montant du crédit formel (=0 sur pop. cible)	Non analytique
Poids_Sondage	Numérique	0,80 – 3,50	Coefficient de pondération pour redressement	Technique

Annexe B - Synthèse des tests statistiques réalisés

Test	Type	Variables testées	Statistique	p-valeur	Décision
Shapiro-Wilk	Normalité	Age	W=0,9377	$4,19 \times 10^{-38}$	Non normale ***
Shapiro-Wilk	Normalité	Revenu_Mensuel_HTG	W=0,8083	$2,08 \times 10^{-56}$	Non normale ***
Mann-Whitney U	Comparaison 2 groupes	Revenu × Milieu	U=2 200 678	$9,21 \times 10^{-57}$	Différence significative ***
Mann-Whitney U	Comparaison 2 groupes	Revenu × Genre	U=2 027 470	$7,40 \times 10^{-1}$	Non significatif ns
Kruskal-Wallis	Comparaison k groupes	Revenu × Secteur	H=2 179,47	≈ 0	Différence significative ***
Kruskal-Wallis	Comparaison k groupes	Revenu × Inclusion	H=148,70	$4,97 \times 10^{-32}$	Différence significative ***
Kruskal-Wallis	Comparaison k groupes	Revenu × Éducation	H=69,41	$5,75 \times 10^{-15}$	Différence significative ***
Kruskal-Wallis	Comparaison k groupes	Revenu × Département	H=100,21	$1,45 \times 10^{-17}$	Différence significative ***
Khi-deux + V Cramér	Association	Epargne × Inclusion	V=0,638	< 0,001	Association forte ***
Khi-deux + V Cramér	Association	Mobile Money × Téléphone	V=0,295	< 0,001	Association modérée ***
Khi-deux + V Cramér	Association	Tontine × Milieu	V=0,003	0,872	Indépendance ns

Spearman	Corrélation	Epargne × Inclusion	$\rho=0,42$	< 0,001	Corrélation modérée ***
Spearman	Corrélation	Revenu × Manque argent	$\rho=-0,24$	< 0,001	Corrélation négative ***
Spearman	Corrélation	Age × Revenu	$\rho=0,00$	0,925	Absence de corrélation ns

Annexe C - Structure des fichiers du projet

Dossier / Fichier	Description	Étape
FinScope_Haiti_2018_Données nettoyées.xlsx	Dataset source — feuilles : Données_Nettoyées, Dictionnaire_Variables, Journal_Nettoyage, Vérification_Statistiques	S2
01_preparation_donnees.ipynb	Filtrage population cible, diagnostic qualité, encodage, standardisation	S2
02_analyse_exploratoire.ipynb	EDA complète : univariée, bivariée, tests statistiques	S3
03_olap_indicateurs.ipynb	Construction des 11 tables agrégées OLAP	S4
Dashboard_Segmentation.pbix	Dashboard Power BI - 4 pages thématiques	S4
04_modelisation_clustering.ipynb	AFDM + K-means + CAH + K-médoïdes + DBSCAN + Méthode mixte	S5
Evaluation.ipynb	Évaluation : stabilité, silhouette, Eta ² , robustesse, pipeline	S6
pipeline_segmentation/scaler.pkl	StandardScaler ajusté	S5-S6
pipeline_segmentation/pca_afdm.pkl	AFDM - PCA 12 composantes	S5-S6
pipeline_segmentation/kmeans_final.pkl	K-means k=6 final	S5-S6
pipeline_segmentation/encodeurs.pkl	Dictionnaires d'encodage + paramètres	S5-S6
pipeline_segmentation/predict.py	Script de prédiction clé en main	S6
pipeline_segmentation/dataset_avec_clusters.csv	Dataset complet avec labels et profils	S5-S6

Annexe D

